




Redes neuronales que aprenden de la experiencia

Las redes de neuronas artificiales pueden aprender a representar información compleja. Tales redes pueden contribuir a la comprensión de las facultades de aprendizaje del cerebro humano

Geoffrey E. Hinton

Constituye el cerebro una computadora muy notable. Es capaz de interpretar información imprecisa suministrada por los sentidos a un ritmo increíblemente veloz. Logra discernir un susurro en una sala ruidosa, un rostro en una callejuela mal iluminada y leer entre líneas en una declaración política. Y lo más impresionante de todo: el cerebro aprende sin instrucciones explícitas de ninguna clase a crear las representaciones internas que hacen posibles tales habilidades.

Mucho se ignora todavía sobre la forma en que el cerebro aprende por sí mismo a procesar información, así que las teorías abundan. Para contrastar tales hipótesis, mis colegas y yo hemos tratado de mimetizar los procesos cerebrales de aprendizaje creando redes de neuronas artificiales. Al construir estas redes de neuronas nos esforzamos primero en deducir los rasgos o características esenciales de las neuronas y de sus interconexiones; la segunda etapa consiste, típicamente, en preparar un programa de ordenador para la simulación de tales características.

Dado que nuestro conocimiento de las neuronas es incompleto y que nuestra capacidad de cómputo es limitada, los modelos son por necesidad idealización burda de las auténticas redes neuronales. Naturalmente, antes de prepararlos debatimos entusiásticamente cuáles habrán de ser los rasgos más esenciales a simular de las neuronas. Al ensayar tales características en redes artificiales hemos podido descartar toda especie de teorías sobre la forma en que el cerebro procesa información. Los modelos están asimismo empezando a revelar de qué manera pudiera lograr el cerebro sus notorias proezas de autodidaxis.

Una neurona típica del cerebro humano recoge señales procedentes de otras a través de una pléyade de delicadas estructuras llamadas dendritas. La neurona emite impulsos de actividad eléctrica a lo largo de una fibra delgada y larga, denominada axón, que se escinde en millares de ramificaciones. En la extremidad de cada rama, una estructura llamada sinapsis convierte la actividad procedente del axón en efectos eléctricos que inhiben o provocan actividad en las neuronas a las que está conectado. Cuando las señales excitadoras que una neurona recibe alcanzan suficiente intensidad frente a las

señales inhibitorias, la neurona envía a lo largo de su axón un breve impulso de actividad eléctrica. El aprendizaje se produce por variación de la efectividad de las sinapsis, de suerte que la influencia de una hormona sobre otra cambia.

Las redes de neuronas artificiales se componen típicamente de "unidades" interconectadas, que cumplen el rol de modelo de neurona. La función de la sinapsis es modelizada atribuyendo a cada conexión un peso modificable. Ninguna red artificial trata de reflejar, en todo su pormenor, la geometría de axones y dendritas; la señal eléctrica de salida de una neurona queda expresada por un solo número que representa la frecuencia de disparo de la neurona, vale decir, su actividad.


Cada unidad convierte la pauta de actividades que en ella ingresan en una única actividad de egreso, que es difundida a otras unidades. Tal conversión se efectúa en dos etapas. Primero, cada actividad aferente es multiplicada por un coeficiente de ponderación (por brevedad, peso) atribuido a la conexión; todos los productos ingresados se suman para obtener una cantidad denominada "entrada total". En una segunda fase, la unidad utiliza una función de transferencia entrada-salida, que transforma el ingreso total en actividad de regreso o "salida".

El comportamiento de una red neuronal artificial depende, a la vez, de los coeficientes de ponderación y de la función de transferencia que sea especificada para las unidades. Tal función se encuadra en una de tres categorías: lineal, de umbral o sigmoide. En el caso de unidades lineales, la actividad de salida es proporcional a la entrada ponderada total. Para unidades de umbral la salida queda fija a uno de dos niveles, dependiendo de que la entrada o ingreso total sea mayor o menor que cierto valor crítico, llamado umbral. En las unidades sigmoideas, la salida varía continuamente con la entrada, pero la dependencia no es lineal. Las unidades sigmoideas guardan mayor parecido con las neuronas reales que las unidades lineales o de umbral; las tres, empero, deben ser tenidas por mera aproximación burda.

Para construir una red neuronal capaz de cierta tarea

1. LAS REDES DE NEURONAS del cerebro dotan a los humanos de la facultad de asimilar información. ¿Llegarán las simulaciones de tales redes a revelar los mecanismos subyacentes al aprendizaje?


GEOFFREY E. HINTON lleva veinte años trabajando en la representación y aprendizaje de redes neuronales. Se recibió de doctor en inteligencia artificial por la Universidad de Edimburgo en 1978. Da clases de informática y psicología en la Universidad canadiense de Toronto.



2. LA NEURONA IDEALIZADA procesa actividades, vale decir, señales. Cada actividad aferente es multiplicada por un coeficiente de ponderación o peso. La “unidad” suma las entradas así ponderadas y computa seguidamente la actividad eferente, o actividad de salida, por medio de una función de transferencia.

específica debemos establecer cómo estarán conectadas unas unidades con otras y determinar adecuadamente los pesos atribuidos a las conexiones. Las conexiones determinan si es posible que una unidad influya sobre otra; los pesos definen la intensidad de la influencia.

El más común de todos los tipos de red neuronal artificial organiza sus elementos en tres niveles o estratos: una capa de unidades de entrada está conectada a un estrato de unidades “ocultas”, conectadas a su vez a las unidades del nivel de salida. La actividad de las unidades de entrada es representación de la información bruta suministrada a la red.



3. UNA RED NEURONAL FRECUENTE es la constituida por tres niveles de unidades interconectadas. La actividad pasa de las unidades de entrada (verde) a las unidades ocultas (gris) y, por fin, a las unidades de salida (amarillo). Los distintos matices de rojo y azul de las unidades representan pesos diferentes.

La actividad de cada unidad oculta está determinada por las actividades de las unidades de entrada y por los pesos de las conexiones entre las unidades de entrada y las unidades ocultas. Análogamente, la conducta de las unidades de salida es función de la actividad de las ocultas y de los pesos que median entre las unidades ocultas y las de salida.

Este sencillo tipo de red posee interés porque las unidades ocultas tienen libertad para construir sus propias representaciones de la entrada. Los pesos que median entre las unidades de ingreso y las unidades ocultas determinan cuándo estará activa cada una de éstas, y así, por modificación de los pesos, una unidad oculta puede decidir el papel que representa.

Cabe enseñar a una red trietápica para que realice una tarea particular, por el siguiente procedimiento. Primero le presentamos a la red una tanda de ejemplos de entrenamiento, ejemplos que consisten en patrones de actividades de las unidades de entrada más los patrones correspondientes que deseamos exhiban las unidades de salida. Determinamos después hasta qué punto existe concordancia entre el egreso real de la red y la salida deseada; por último se modifican los pesos de cada conexión, buscando que la red consiga una mejor aproximación de la salida deseada.

Supongamos, sea por caso, que nuestra red deba reconocer cifras escritas a mano. Podríamos utilizar una matriz de 256 sensores, por ejemplo, que registren cada uno la presencia

o ausencia de tinta en una diminuta porción de una región que sólo contiene un dígito. La red precisaría entonces 256 unidades de entrada (una por sensor), diez unidades de salida (una por dígito) y cierto número de unidades ocultas. Para cada tipo de dígito registrado por los sensores, la red debería producir una elevada actividad en la unidad de salida adecuada y baja actividad en las restantes.

Para entrenar a la red, le presentamos una imagen de un dígito y comparamos la actividad real de las diez unidades de salida con la actividad deseada. Calculamos seguidamente el error, que se define como la suma de los cuadrados de las discrepancias entre actividades reales y deseadas; cambiamos ahora el peso de cada conexión, al objeto de reducir el error. Podemos repetir el proceso de entrenamiento para muchas diferentes imágenes de cada tipo de dígito, hasta conseguir que la red clasifique correctamente cada imagen.

Para poner en práctica tal procedimiento, la magnitud de la modificación de cada peso debería ser proporcional a la tasa relativa de variación del error con respecto a la variación de ese peso. Esta cantidad, que se llama “derivada respecto al peso”, o simplemente, EP para recordar “error de peso”, es difícil de calcular eficientemente. Una forma de calcular el EP consiste en perturbar levemente un peso y observar cómo varía el error. Tal método es ineficiente, porque requiere una perturbación individual para cada peso, y éstos, de ordinario, serán muchos.

Hacia 1974, Paul J. Werbos, doctorando en la Universidad de Harvard, ideó un procedimiento mucho más eficiente para calcular el EP. Tal procedimiento, hoy conocido por algoritmo de retropropagación, se ha convertido en uno de los principales instrumentos para el entrenamiento de redes neuronales.

El algoritmo de retropropagación resulta más sencillo de comprender en el caso de que todos los elementos de la red sean lineales. El algoritmo computa cada EP hallando primero el “error de actividad”, EA, tasa de variación del error al cambiar el nivel de actividad de una unidad. Para unidades de salida, el EA es sencillamente la diferencia entre la salida deseada y la real. Para calcular el EA correspondiente a una unidad oculta del nivel inmediatamente inferior al de salida se empieza por identificar todos los pesos que median entre esa unidad oculta y las unidades de salida a las que

está conectada. Multiplicamos entonces esos coeficientes de ponderación por los errores de actividad de tales unidades de salida y sumamos los productos. Esta suma es igual al EA de la unidad oculta elegida. Después de calcular todos los EA de la capa oculta inmediatamente subyacente a la de salida, podemos calcular de igual manera los EA correspondientes a las restantes capas, pasando de una capa a otra en sentido opuesto al de propagación de actividades a través de la red. De aquí el nombre de retropropagación. En cuanto el EA ha sido computado para una unidad, el cálculo del EP (error de ponderación) correspondiente a cada conexión entrante en la unidad resulta inmediato. El EP es el producto del EA y de la actividad a través de la conexión entrante.

En el caso de unidades no lineales, el algoritmo de retropropagación

exige un paso más. Antes de la retropropagación es preciso convertir el EA en EI (error de ingreso), que es la tasa con que cambia el error al variar el ingreso total recibido por una unidad. (Pueden verse los detalles de este cálculo en el recuadro que se adjunta.)

El algoritmo de retropropagación permaneció en el olvido durante bastantes años, debido con toda probabilidad a que su utilidad no fue valorada como merecía. A principios del decenio de 1980, David E. Rumelhart, a la sazón en la Universidad de California en San Diego, y David B. Parker, que hallábase entonces en la Universidad de Stanford, redescubrieron independientemente el algoritmo. En 1986, Rumelhart, Ronald J. Williams (de San Diego) y quien escribe popularizamos el algoritmo al demostrar que lograba enseñar a las unidades ocultas, consiguiendo



que éstas produjeran representaciones interesantes de patrones complejos ofrecidos como entrada.

El algoritmo de retropropagación ha demostrado poseer una sorprendente eficacia para entrenar redes neuronales poliestratificadas y conseguir que éstas desempeñen un amplio abanico de tareas. El algoritmo es de máxima utilidad en situaciones donde la entrada y la salida guardan relación no lineal y hay abundante provisión de datos de entrenamiento. Valiéndose del algoritmo, los investigadores han producido redes neuronales que reconocen dígitos manuscritos, predicen las tasas cambiarias de las divisas y optimizan el rendimiento de ciertos procesos químicos. El algoritmo ha sido utilizado incluso para entrenar redes que identifican células precancerosas en frotis de Pap o capaces de ajustar el espejo de un telescopio para compensar

Representación de dígitos manuscritos en una red

Se ha instruido a esta red neuronal, compuesta por 256 unidades de entrada, nueve unidades ocultas y diez unidades de salida, para reconocer dígitos manuscritos. La ilustración al pie expone las actividades de las unidades cuando se le presenta a la red un 3 manuscrito. Los nueve paneles de la derecha representan los 256 pesos aferentes y los diez pesos eferentes correspondientes a cada una de las nueve unidades ocultas.

SALIDA
OCULTA
ENTRADA



y eliminar las distorsiones de naturaleza atmosférica.

En el campo de las neurociencias, Richard Andersen, del Instituto de Tecnología de Massachusetts (MIT), y David Zipser, de la Universidad de California en San Diego, han demostrado que el algoritmo de retropropagación constituye un instrumento útil para explicar la función de ciertas neuronas de la corteza cerebral. Estos investigadores aplicaron la retropropagación en el entrenamiento de una red neuronal que habría de responder a estímulos visuales. Hallaron después que las respuestas de las unidades ocultas se asemejaban sorprendentemente a las de neuronas auténticas responsables de la conver-

sión de información visual procedente de la retina a formas más adecuadas para áreas visuales ubicadas más profundamente en el cerebro.

Sin embargo, en cuanto teoría del aprendizaje real de las neuronas biológicas, la retropropagación ha sido recibida con división de opiniones. Por una parte, el algoritmo de retropropagación ha supuesto una valiosa aportación a nivel abstracto. El algoritmo es francamente eficiente en la creación de representaciones verosímiles en las unidades ocultas. En consecuencia, los investigadores adquirieron confianza y han ido acertando con procedimientos en los cuales los pesos son gradualmente

ajustados para reducir errores. Hasta entonces, eran muchos los investigadores que suponían que esta clase de métodos no ofrecerían ninguna posibilidad, por conducir inevitablemente a soluciones localmente óptimas, pero globalmente muy malas. Por ejemplo, una red de reconocimiento de dígitos podría converger sistemáticamente hacia una distribución de pesos que confundiera unos y siete, no obstante existir un sistema de pesos que permitiría a la red discriminar claramente entre ambos dígitos. Este temor vino a respaldar la extendida convicción de que un proceso de aprendizaje sólo sería interesante cuando estuviera garantizada su convergencia hacia la solución global-

El algoritmo de retropropagación

Para que una red neuronal realice una tarea es preciso ajustar los pesos de cada unidad de modo tal que se reduzca el error entre la salida deseada y la conseguida. Tal proceso requiere que la red neuronal compute la derivada del error respecto a los pesos (EP), esto es, debe calcular cuánto varía el error al modificar levemente en más y en menos cada uno de los pesos. El método habitual para la determinación del EP es el algoritmo de propagación retrógrada.

Para llevar a la práctica el algoritmo de retropropagación es necesario ante todo dar una descripción matemática de la red neuronal. Supongamos que la j -ésima unidad sea una unidad típica del nivel de salida y que la unidad i -ésima sea también típica en el nivel inmediatamente inferior. Las unidades del nivel de salida determinan su actividad atendiendo a un procedimiento en dos pasos. Calculan primero la entrada total ponderada x_j mediante la fórmula

$$x_j = \sum_i y_i w_{ij},$$

siendo y_i el nivel de actividad de la i -ésima unidad del estrato inferior y w_{ij} el peso de la conexión entre las unidades i -ésima y j -ésima.

Seguidamente, la unidad calcula la actividad y_j aplicando una función a la entrada total ponderada. La función típicamente utilizada es la función sigmoide:

$$y_j = \frac{1}{1 + e^{-x_j}}.$$

Una vez determinadas las actividades de todas las unidades de salida, la red computa el error cuadrático $\mathcal{E}$, definido por la expresión

$$\mathcal{E} = \frac{1}{2} \sum_j (y_j - d_j)^2,$$

en la cual y_j es el nivel de actividad de la unidad j -ésima del nivel superior y d_j es la salida deseada de la unidad j -ésima.

El algoritmo de retropropagación consta de cuatro pasos:

1. Cómputo de la rapidez de variación del error al cambiar la actividad de una unidad de salida. Esta derivada del error (EA) es la diferencia entre las acti-

vidades real y deseada.

$$EA_j = \frac{\partial \mathcal{E}}{\partial y_j} = y_j - d_j$$

2. Cómputo de la rapidez de variación del error al cambiar la entrada total que recibe una unidad de salida. Esta cantidad (EI) es el resultado del paso 1 multiplicado por la tasa de variación de la salida de una unidad con relación a las variaciones de su entrada total.

$$EI_j = \frac{\partial \mathcal{E}}{\partial x_j} = \frac{\partial \mathcal{E}}{\partial y_j} \frac{dy_j}{dx_j} = EA_j y_j (1 - y_j)$$

3. Cómputo de la rapidez de variación del error al ser modificado un peso de la conexión aferente a una unidad de salida. Esta cantidad (EP) es el resultado del paso 2 multiplicado por el nivel de actividad de la unidad de la cual emana la conexión.

$$EP_{ij} = \frac{\partial \mathcal{E}}{\partial w_{ij}} = \frac{\partial \mathcal{E}}{\partial x_j} \frac{\partial x_j}{\partial w_{ij}} = EI_j y_i$$

4. Cómputo de la rapidez de variación del error al cambiar la actividad de una unidad del nivel inmediatamente inferior. Este es el paso crucial que permite aplicar la retropropagación a redes polietápicas. Las actividades de todas las unidades de salida a las que está conectada una unidad del nivel precedente quedan modificadas al variar ésta su actividad. Por tanto, para calcular el efecto global sobre el error sumaremos todos estos efectos individuales sobre las unidades de salida. Ahora bien, cada efecto es sencillo de calcular. Es el resultado del paso 2 multiplicado por el peso asignado a la conexión aferente a esa unidad de salida.

$$EA_i = \frac{\partial \mathcal{E}}{\partial y_i} = \sum_j \frac{\partial \mathcal{E}}{\partial x_j} \frac{\partial x_j}{\partial y_i} = \sum_j EI_j w_{ij}$$

Merced a los pasos 2 y 4 podemos convertir los errores de actividad (EA) de un estrato de unidades en EA del estrato subyacente. Podemos calcular por iteración del procedimiento los EA de tantas capas de unidades como sea necesario. Una vez conocido el EA de una unidad podemos aplicar los pasos 2 y 3 para calcular los EP de sus conexiones aferentes.


mente óptima. La propagación retrógrada demostró que, en muchas tareas, no es necesaria la convergencia global para conseguir funcionamientos adecuados.

Por otra parte, la propagación retrógrada no parece ser biológicamente plausible. La dificultad más obvia estriba en que la información ha de viajar por unas mismas conexiones en sentido retrógrado, desde cada estrato al precedente. Como es obvio, no ocurre así en las neuronas reales. Pero esta objeción es en realidad bastante superficial. El cerebro es rico en redes que retrogradan de unas capas a otras anteriores y podría utilizar estas sendas de múltiples formas para aportar la información que el aprendizaje requiere.

De mayor entidad es el problema que plantea la velocidad del algoritmo de retropropagación. La cuestión relevante es ahora el ritmo de crecimiento del tiempo de aprendizaje necesario al crecer el tamaño de la red. El tiempo invertido en calcular, para un ejemplo dado, las derivadas del error respecto a los pesos es proporcional al tamaño de la red, porque el volumen de cómputo es proporcional al número de pesos. Además, cuanto mayor es la red, más ejemplos y mayor es el número de veces que se han de corregir los pesos; por consiguiente, el tiempo de aprendizaje crece mucho más rápidamente que el tamaño de la red.

Pero la objeción más seria que suscita la retropropagación en cuanto modelo del aprendizaje real es que requiere de un instructor que proporcione la salida deseada para ejemplo de entrenamiento. Las personas, por el contrario, pueden aprender casi todo sin auxilio de instructores. Para sacar partido de las señales enviadas por nuestros sentidos no es preciso que nos sea expuesta antes una descripción detallada del mundo. Por el contrario, aprendemos a comprender frases o escenas visuales sin instrucciones explícitas de ninguna clase.

¿Cómo podría una red adquirir representaciones internas apropiadas del mundo, si carece al empezar de conocimientos y de maestro? Cuando se le presenta a la red una gran colección de patrones de entrada sin que se le dé información sobre lo que debe hacer con ellos, la red se encuentra, aparentemente, libre de problema bien definido que resolver. No obstante, los investigadores han diseñado varios procedimientos de uso general, no supervisados, que pueden ajustar adecuadamente los pesos de la red.




4. DOS CARAS compuestas por ocho elipses pueden ser representadas mediante puntos individuales en dos dimensiones. Por otra parte, dado que las elipses solamente se diferencian de cinco formas (orientación, posición horizontal del centro, posición vertical del centro, anchura y altura), también es posible representar las dos caras como ocho puntos de un espacio de cinco dimensiones.

Todos estos procedimientos comparten dos características: apelan, implícita o explícitamente, a cierta noción de la calidad de la representación y funcionan cambiando los pesos para mejorar la representación extraída por las unidades ocultas.

En general, las representaciones de calidad se distinguen por admitir una descripción muy económica y contener, no obstante, información suficiente para reconstruir una entrada "en rama" con buena aproximación.

Imaginemos, por ejemplo, una imagen formada por varias elipses. Supongamos que cierto dispositivo traduce la imagen a una matriz compuesta por un millón de diminutos puntitos, cada uno de los cuales puede ser claro u oscuro. La imagen podría quedar representada simplemente por las posiciones de los cuadrados oscuros. Pero caben también otras representaciones más eficientes. Las elipses se diferencian en sólo cinco aspectos: orientación, posición



5. EL APRENDIZAJE COMPETITIVO puede ser contemplado como un proceso en el que cada serie o patrón de entrada atrae la distribución de pesos de la unidad oculta más próxima. Cada patrón aferente representa un conjunto de rasgos distintivos. La distribución de pesos de las unidades ocultas se ajusta de forma que vayan migrando lentamente hacia el sistema más cercano de patrones de entrada. Con esa pauta, cada unidad oculta aprende a representar un racimo de patrones similares.

vertical, posición horizontal, longitud y anchura. Por consiguiente, la imagen puede quedar descrita utilizando solamente cinco parámetros por elipse.

Aunque la descripción de una elipse mediante cinco parámetros exige más bits que la descripción de un único cuadrado negro mediante dos coordenadas, podemos lograr un ahorro global porque hay que manejar muchísimo menor número de parámetros que de pares coordinados. Además, la descripción de las elipses mediante parámetros no comporta la menor pérdida de información: dados los parámetros de la elipse, podríamos, si quisiéramos, reconstruir de manera perfecta la imagen original.

Casi todos los procedimientos de aprendizaje no supervisado pueden ser considerados métodos de minimización de la suma de dos términos, a saber, un costo de codificación y un costo de reconstrucción. El costo de codificación es el número de bits requeridos para la descripción de las actividades de las unidades ocultas. El costo de reconstrucción es el número de bits requeridos para describir el desajuste entre la entrada en rama y la aproximación óptima de ella que podríamos reconstruir a partir de las actividades de las unidades ocultas. El costo de reconstrucción es proporcional al cuadrado de la diferencia entre la entrada en rama y su reconstrucción.


Existen dos métodos sencillos para el descubrimiento de códigos económicos que permitan una reconstrucción bastante exacta de la entrada. Son éstos el aprendizaje de componentes principales y el aprendizaje competitivo. En ambas técnicas, empezamos decidiendo cuán económico ha de ser el código y modificando después los pesos para así reducir el error de reconstrucción.

La estrategia de aprendizaje por componentes principales se funda en la idea de que, si las actividades de parejas de unidades de entrada guardan entre sí algún tipo de correlación, la descripción por separado de cada actividad de entrada sería un desperdicio de bits. Una técnica más refinada consistiría en extraer y describir las componentes principales, es decir, las componentes de variación compartidas por multitud de unidades de entrada. Si deseamos describir, por ejemplo, diez de las componentes principales,

necesitaremos una única capa de diez unidades ocultas.

Dado que tales redes representan la entrada con sólo un pequeño número de componentes, el costo de codificación es barato. Y, dado que la entrada admite una reconstrucción francamente buena a partir de las componentes principales, el costo de reconstrucción también es reducido.

Una forma de entrenar redes de este tipo consiste en obligarlas a re-



6. LA CODIFICACION DEMOGRAFICA representa un objeto multiparamétrico en forma de protuberancia de actividad extendida sobre muchas unidades ocultas. Cada disco simboliza una unidad oculta inactiva; cada cilindro, una unidad oculta activa, cuya altura denota el nivel de actividad.

construir una aproximación de la entrada sobre un sistema de unidades de salida. Se puede utilizar después la retropropagación con el fin de minimizar la diferencia entre la salida real y la deseada. Este proceso se asemeja al de aprendizaje supervisado, pero dado que la salida deseada es exactamente la misma que la entrada, no es necesario instructor.

Muchos investigadores, entre quienes figuran Ralph Linsker, del Centro de Investigación Thomas J. Watson, de IBM, y Erkki Oja, de la Universidad Politécnica de Lappeenranta, han descubierto algoritmos de otros tipos para el aprendizaje de componentes principales. Dichos algoritmos son biológicamente más plausibles, porque no requieren unidades de salida ni retropropagación. Para determinar las modificaciones de pesos se valen, en cambio, de las correlaciones entre las actividades de las unidades ocultas y las actividades de las unidades de entrada.

Cuando una red neuronal se sirve del aprendizaje por componentes principales, un pequeño número de unidades ocultas coopera en la representación de la pauta de entrada. En el aprendizaje competitivo, contrariamente, un gran número de unidades ocultas pugnan entre sí, con lo que finalmente se utiliza una sola unidad oculta para la representación de un patrón de entrada determinado. La unidad oculta se-

leccionada es aquella cuyos pesos incidentes se asemejan más al patrón de entrada.

Supongamos ahora que fuera preciso reconstruir el patrón de entrada conociendo solamente cuál ha sido la unidad oculta seleccionada. La conjetura óptima sería, obviamente, copiar la distribución de pesos de las líneas entrantes en tal unidad oculta. Para minimizar el error de reconstrucción, habría que aproximar todavía más la distribución de pesos de la unidad oculta ganadora a los valores auténticos del patrón de entrada. Pues eso es lo que hace el aprendizaje competitivo. Cuando a la red le son presentados datos de aprendizaje que cabe apiñar en grupos de entradas similares, cada unidad oculta aprende a representar un racimo diferente y sus pesos incidentes convergen en el centro del racimo en cuestión.

Al igual que el algoritmo de componentes principales, el aprendizaje competitivo logra minimizar el costo de reconstrucción y mantener bajo el costo de codificación. Podemos permitirnos utilizar muchas unidades ocultas, porque incluso con un millón de unidades se requieren sólo 20 bits para expresar la vencedora.

A principios del decenio pasado, Teuvo Kohonen, de la Universidad de Helsinki, introdujo en el algoritmo de aprendizaje competitivo una modificación importante. Kohonen mostró la forma de conseguir que unidades físicamente adyacentes aprendieran a representar patrones de entrada similares. El algoritmo de Kohonen no sólo adapta los pesos de la unidad oculta ganadora, sino también los pesos de las unidades vecinas a ésta. La capacidad del algoritmo para trasladar a unidades ocultas cercanas aquellos patrones de entrada que sean similares sugiere la posibilidad de que el cerebro recurra a un procedimiento de este tipo para crear los mapas topográficos hallados en la corteza visual.


Podemos clasificar los algoritmos de aprendizaje no supervisado atendiendo al tipo de representación creado por ellos. En los métodos basados en componentes principales, las unidades ocultas cooperan y la representación de cada pauta de entrada resulta distribuida por todas ellas. En los métodos competitivos, las unidades ocultas compiten y la representación del patrón de entrada

queda localizada en la única unidad oculta finalmente seleccionada. Hasta hace poco, casi todas las investigaciones sobre aprendizaje no supervisado centrábanse en una u otra de estas dos técnicas, debido, quizás, a que daban pie a reglas sencillas para la modificación de los pesos. Pero es probable que los algoritmos más potentes e interesantes ocupen alguna posición intermedia entre los extremos correspondientes a representaciones distribuidas puras y representaciones puramente locales.

Horace B. Barlow, de la Universidad de Cambridge, ha propuesto un modelo en el cual cada unidad oculta raramente se encuentra activa y en que la representación de cada patrón de entrada hállase distribuida sobre un pequeño número de unidades ocultas seleccionadas. Barlow y colaboradores han demostrado que este tipo de codificación puede ser aprendido obligando a las unidades ocultas a hallarse incorrelacionadas y asegurando, al propio tiempo, que la codificación oculta permita una buena reconstrucción de la entrada.

Para nuestro infortunio, la mayoría de los métodos utilizados para minimizar el costo de codificación propenden a eliminar toda la redundancia entre las actividades de las unidades ocultas; por culpa de ello, la red se resiente de las disfunciones, aunque sólo sea una la que opere incorrectamente. No es éste uno de los rasgos característicos del cerebro, que por lo común no resulta muy afectado por la pérdida de unas cuantas neuronas.

Parece como si el cerebro utilizase los denominados "códigos demográficos", en los cuales la información es representada mediante toda una población de neuronas activas. Dicha tesis quedó elegantemente manifiesta en los experimentos de David L. Sparks y colaboradores, de la Universidad de Alabama. Mientras estudiaban en monos el mecanismo en virtud del cual el cerebro indica a los ojos en qué dirección han de moverse, hallaron que el movimiento se encuentra codificado por las actividades de toda una población de células, cada una de las cuales representa un movimiento ocular un poco diferente. El movimiento resultante corresponde al promedio de todos los codificados por las células activas. Al anestesiarse algunas células cerebrales, el ojo se mueve hacia el punto asociado con el promedio de las células activas restantes. Los códigos demográficos pueden emplearse para codificar no sólo



7. PROMINENCIAS DE ACTIVIDAD en conjuntos de unidades ocultas; representan la imagen de una nariz y una boca. Estos códigos demográficos provocarán una prominencia en las unidades faciales si boca y nariz en encuentran en posición relativa correcta (*izquierda*). De no ser así, las unidades nasales activas tratarán de crear una prominencia en cierta ubicación mientras que las unidades bucales activas harán lo propio en diferente lugar. En consecuencia, la actividad aferente a las unidades faciales no supera el valor umbral y no se forma prominencia en dichas unidades (*derecha*).

movimientos oculares, sino también rostros, acaban de comprobar Malcolm P. Young y Shigeru Yamane en el Instituto RIKEN, en sus experimentos con la corteza temporal inferior de monos.

Tanto en el caso de los movimientos oculares como en el de los rostros, el cerebro ha de representar entidades que varían según muchas dimensiones. En el caso de un movimiento ocular las dimensiones sólo son dos; mas, para rostros y similares existen dimensiones como felicidad, pilosidad o familiaridad, amén de parámetros espaciales como la posición, el tamaño y la orientación. Si asociamos a cada célula sensible al rostro los parámetros faciales que la hacen más activa, podemos promediar estos parámetros sobre una población de células activas con el fin de descubrir los parámetros del rostro que se están representando por ese código

demográfico. En términos abstractos, cada célula facial representa un punto particular de un espacio multidimensional de rostros posibles, y cada faz puede ser entonces representada por activación de todas las células que codifican caras muy parecidas, evidenciándose así una prominencia de actividad en el espacio multidimensional de rostros posibles.

La codificación poblacional resulta atractiva porque sigue funcionando, aun cuando se lesionen algunas neuronas. Ello se debe a que la pérdida de un subconjunto de neuronas tomado al azar tiene escasos efectos sobre el promedio de la población. El mismo razonamiento subsiste si el sistema trabaja con prisa y no toma en consideración ciertas neuronas. Las neuronas se comunican enviando breves impulsos eléctricos discretos que reciben el nombre de potenciales de acción; si el intervalo de tiempo

es muy breve, puede que muchas de las neuronas "activas" no tengan ocasión de enviar impulsos. No obstante, incluso en un intervalo tan breve, un código demográfico de una parte del cerebro puede todavía suscitar un código poblacional aproximadamente correcto en otra región del cerebro.

A primera vista, la redundancia característica de los códigos demográficos parece incompatible con el principio de que la construcción de representaciones internas debe hacer mínimo el costo de codificación. Felizmente, podemos superar esta dificultad valiéndonos de una medición menos directa del costo de codificación. Si la actividad que codifica una entidad particular consiste en una protuberancia lisa, donde la actividad se amortigua al alejarnos del centro según un patrón normalizado, podremos describir entera la protuberancia de actividad con sólo especificar su centro. Por consiguiente, el costo de la descripción del centro de la prominencia de actividad, sumado al costo de la descripción de la forma en que las actividades reales de las unidades se apartan de la prominencia lisa de actividad deseada, proporcionaría una medida más equitativa del costo de codificación.

Al utilizar esta medida del costo de codificación, hallamos que los códigos poblacionales, o demográficos, proporcionan formas convenientes para extraer una jerarquía de codificaciones progresivamente más eficientes de las señales aportadas por los sentidos. Un ejemplo sencillo permitirá ilustrar mejor esta tesis. Imaginemos que a una red neuronal le es presentada la imagen de un rostro. Supongamos que la red contiene ya un conjunto de unidades dedicadas a la representación de narices, otro a la de bocas y un tercero a las representaciones de ojos. Cuando le sea mostrada una cara, se producirá una prominencia de actividad en las unidades nasales, otra en las orales y dos en el conjunto de unidades oculares. La ubicación de cada una de estas prominencias de actividad representa los parámetros espaciales del rasgo codificado por la prominencia. La descripción de las cuatro prominencias de actividad es más económica que la descripción de la imagen en rama; obviamente, todavía resultaría más económica la descripción de una sola prominencia de actividad en un conjunto de unidades faciales, suponiendo, evidentemente, que la nariz, la boca y los ojos guarden entre sí las relaciones

espaciales correctas para definir un rostro.

Lo cual plantea una cuestión interesante: ¿cómo puede la red verificar que las partes guardan la relación debida para perfilar una imagen facial? Hace algún tiempo, Dana H. Ballard, de la Universidad de Rochester, introdujo una sagaz técnica para resolver este tipo de problemas, que funciona muy bien en el caso de códigos demográficos.

Si conocemos la posición, el tamaño y la orientación de una nariz, podemos predecir la posición, orientación y tamaño del rostro al que pertenece, porque la relación espacial entre narices y caras es sensiblemente fija. Establecemos en consecuencia los pesos de la red neuronal de forma que una prominencia de actividad en las unidades nasales trate de provocar una prominencia de actividad convenientemente relacionada en las unidades faciales. Pero establecemos también los umbrales de las unidades faciales de forma que las nasales no consigan por sí solas provocar la activación de aquéllas. Empero, si la prominencia de actividad de las unidades correspondientes a la boca intenta asimismo provocar una prominencia de unidades faciales en el mismo lugar, resulta posible superar los niveles umbrales. Lo que así se ha conseguido es verificar que la nariz y la boca se encuentran correctamente relacionadas entre sí, al comprobar que ambas predicen los mismos parámetros espaciales para el rostro entero.

Este método de verificación de relaciones espaciales llama la atención porque se vale del tipo de redundancia entre distintas partes de una imagen que el aprendizaje no supervisado sabría descubrir. Parece, pues, natural recurrir al aprendizaje no supervisado para hallar códigos demográficos jerárquicos y extraer entonces figuras complejas. En 1986, Eric Saund, del MIT, exhibió un método de aprendizaje de códigos poblacionales para detección de formas. Parece verosímil que, con una definición clara del costo de codificación, una red no supervisada podrá descubrir jerarquías más complejas al tratar de minimizar el costo de codificación de la imagen. En la Universidad de Toronto, Richard Zemel y quien escribe estamos investigando tal posibilidad.

Utilizando aprendizaje no supervisado para la extracción de una jerarquía de representaciones de economía creciente habría que acelerar mucho la velocidad de aprendizaje en redes grandes multietápicas. Cada

etapa de la red adapta los pesos de sus líneas de ingreso con el propósito de lograr que su representación sea superior a la de la etapa precedente, para que cada etapa aprenda los pesos sin referencia a los pesos de etapas subsiguientes. Tal estrategia elimina muchas de las interacciones entre pesos, responsables de que el aprendizaje por retropropagación sea muy lento en redes profundas y poliestratificadas.

Todos los procedimientos de aprendizaje descritos hasta aquí se han llevado a la práctica en redes neuronales donde la actividad fluye solamente en dirección progresiva, desde la entrada hacia la salida, a pesar de que el flujo de las derivadas del error pueda cursar en sentido retrógrado. Otra posibilidad importante reside en las redes cuya actividad fluye en bucles cerrados. Tales redes recurrentes pueden alcanzar estados estacionarios o exhibir una dinámica temporal compleja, utilizable quizá para producir un comportamiento secuencial. En el caso de que lleguen a estados estacionarios, las derivadas del error son calculables por métodos mucho más sencillos que la retropropagación.

Aunque los investigadores han desarrollado potentes algoritmos de aprendizaje, de gran valor práctico, seguimos sin saber cuáles son las representaciones y procedimientos de aprendizaje de que se sirve el cerebro. Pero antes o después, los estudios computacionales del aprendizaje en redes neuronales artificiales acabarán por converger en los métodos descubiertos por evolución. Cuando así acontezca, muchísimos datos empíricos concernientes al cerebro comenzarán súbitamente a adquirir sentido y se tornarán factibles muchas aplicaciones desconocidas de las redes neuronales.

BIBLIOGRAFIA COMPLEMENTARIA

- LEARNING REPRESENTATIONS BY BACK-PROPAGATING ERRORS. David E. Rumelhart, Geoffrey E. Hinton y Ronald J. Williams en *Nature*, vol. 323, n.º 6188, págs. 533-536; 9 de octubre de 1986.
- CONNECTIONIST LEARNING PROCEDURES. Geoffrey E. Hinton, en *Artificial Intelligence*, vol. 40, n.ºs 1-3, págs. 185-234; septiembre de 1989.
- INTRODUCTION TO THE THEORY OF NEURAL COMPUTATION. J. Hertz, A. Krogh y R. G. Palmer. Addison-Wesley, 1990.
- THE COMPUTATIONAL BRAIN. Patricia S. Churchland y Terrence J. Sejnowski. The MIT Press/Bradford Books, 1992.